Clasificación de los niveles de demencia según radiografías cerebrales

Daniel Naranjo Garcia

22 de octubre de 2025

1 Descripción del dataset

El dataset escogido ha sido seleccionado en kaggle y consiste en 86.470 imágenes de radiografías de cerebros humanos.[1] El dataset está dividido en cuatro carpetas para clasificar las imágenes según el nivel de demencia que poseia la persona de dicha radiografía. El nombre de las carpetas son las siguientes: 'Non Demented', 'Moderate Dementia', 'Mild Dementia' y 'Very mild Dementia'.
En la Figura 1 se puede ver la distribución de las imágenes en las carpetas mediante una gráfica. Se puede observar una gran cantidad de imagenes en la carpeta 'Non Demented' mientras que en el resto hay muchas menos. Debido a esto, en las fases de selección de imágenes para el conjunto de entrenamiento y el de pruebas, tendremos que tener en cuenta de limitar la cantidad de imágenes a escoger entre las clases para no sobreentrenar al modelo con imágenes de una misma clase.

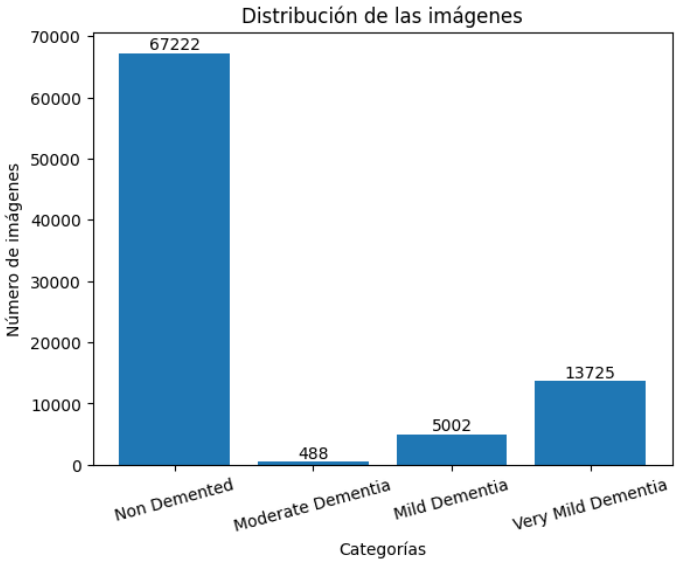

Figure 1: Distribución del dataset

2 Evaluación con modelos (Ver notebook Modelos Lineales)

Para la evaluación del dataset OASIS con modelos lineales, se han utilizado cuatro tipos de modelos y se han comparado sus resultados explicando las ventajas y desventajas que ofrecen respecto del dataset. Cada modelo se ha ejecutado 10 veces para obtener la media de los resultados.

2.1 Naive Bayes

Naive Bayes considera cada dato de forma independiente, es decir, que cada dato no tiene correlación con los otros datos. En el caso del dataset OASIS, los datos (píxeles de las imágenes) están altamente relacionados por lo que Naive Bayes no será capaz de realizar buenas predicciones.

Tras aplicar el modelo Naive Bayes obtenemos una media del 39% de precisión.

2.2 Análisis de Componentes Principales (PCA)

Para poder aplicar los siguientes modelos de análisis lineal ha sido necesario utilizar PCA para reducir la dimensión de las imágenes.

Sin reducir la dimensión de las imágenes, se obtenía un conjunto de entrenamiento con 9600 imágenes de 49152 características cada una. Utilizando PCA reducimos el conjunto de entrenamiento a 9600 imágenes de 6000 características

cada una. Al reducir las características de las imágenes reducimos la cantidad de parámetros que tienen que aprender los modelos reduciendo así el riesgo de sobreajuste.

En la Figura 2 se comprueban diferentes valores para reducir la dimensionalidad utilizando PCA. Tras el análisis de dichos resultados, se ha decidido reducir las imágenes a 6000 dimensiones.

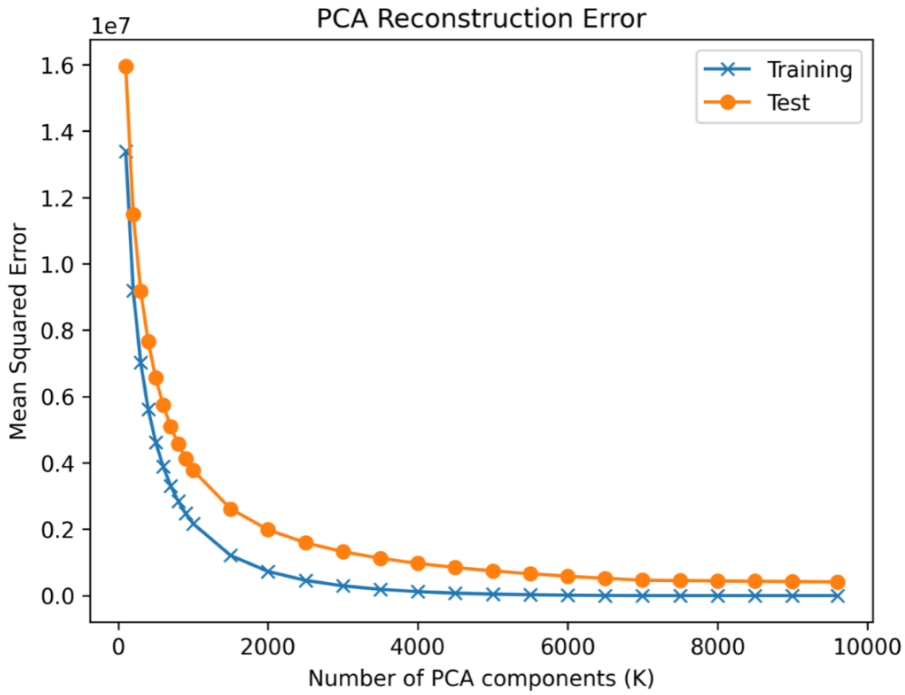

Figure 2: Gráfica comparando diferentes dimensiones

2.3 Análisis Discriminante Lineal

El modelo de Análisis Discriminante Lineal asume una matriz de covarianzas común para todas las clases por lo que se tienen en cuenta las correlaciones entre las características de los datos. Teniendo en cuenta que se usan 9600 imágenes de entrenamiento y que se ha reducido la dimensión de las imágenes, la matriz de covarianzas va a ser fiable debido a la gran cantidad de muestras.

La precisión conseguida con este modelo es de una media del 90,44%.

2.4 Análisis Discriminante Cuadrático (QDA)

Este modelo de análisis estima para cada clase del dataset una matriz de covarianzas. Debido a que el conjunto utilizado es pequeño y que las cantidades de imágenes entre clases es muy distinta, QDA puede presentar problemas.

Como QDA genera matrices de covarianzas para cada clase, las matrices correspondientes a esas clases con menos imágenes pueden no ser fiables. Dado estos incovenientes, la precisión conseguida utilizando QDA es de un media de 49,11%

2.5 Regresión Logística

La Regresión Logística se puede utilizar para la clasificación de imágenes. En este caso, la regresión logística multiclase emplea la función softmax para obtener un vector de probabilidades para indicar la pertenencia de una imagen a cada clase.

Con las imágenes del dataset OASIS, el modelo de regresión logística, tras aplicar PCA es capaz de clasificar correctamente las imágenes porque son más fáciles de separar linealmente.

Los cambios entre las clases del dataset OASIS suelen ser cambios por ejemplo en el volumen del cerebro o en el hipocampo [2]. Este tipo de diferencias puede ser captadas correctamente utilizando modelos lineales como regresión logística.

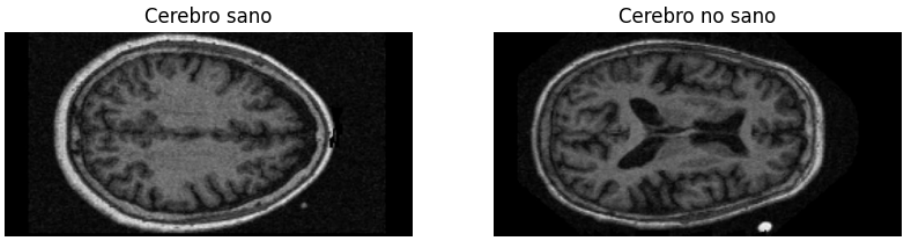

Figure 3: Cerebros con y sin alzheimer

En la Figura 4 se puede ver una gráfica de barras comparando los cuatro modelos lineales utilizados. Tras probar los diferentes modelos lineales, el mejor ha sido el de regresión logística con una precisión de media del 93,81%.

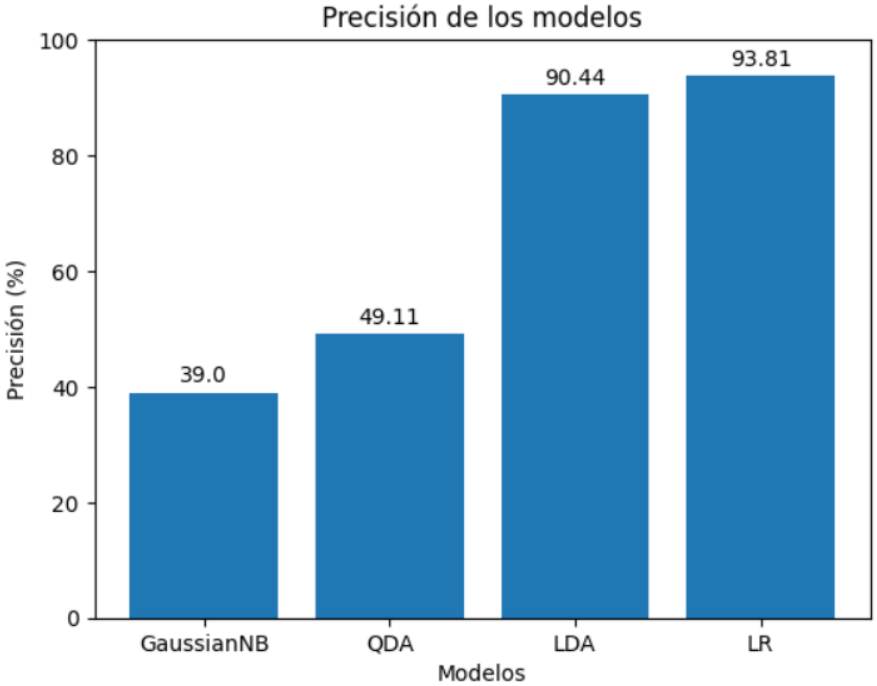

Figure 4: Precisión de los modelos lineales

3 Redes Neuronales

En esta sección se va a realizar experimentos con redes neuronales simples probando diferentes cantidades de capas y neuronas para intentar buscar la mejor red neuronal para el dataset OASIS.

Posteriormente, se probarán diferentes tipos de redes convolucionales para comprobar si con este tipo de redes mejora la precisión comparado con el resto de modelos vistos en el proyecto.

Para cada experimento se explicarán las ventajas que ofrece cada tipo de red neuronal.

3.1 Perceptrones Multicapa (MLP) (Ver MLP Notebook)

Para evaluar este tipo de redes se ha realizado un ajuste de hiperparámetros utilizando keras tuner. Con esta herramienta se han generado varias redes que tengan entre dos y cinco capas ocultas. El valor de neuronas de cada capa oculta se ha especificado en un rango entre 128 y 2048. Luego se añadía una capa dropout con un valor mínimo de 0.2 y máximo de 0.5.

El uso de las capas dropout es importante. Su función es deshabilitar un número de neuronas para evitar así el sobreajuste y mejorar la generalización.

Por último, también se han escogido diferentes tasas de aprendizaje que son los siguientes: [1e-2, 1e-3, 1e-4].

La desventaja que ofrece los MLP es que si son redes profundas, para realizar el entrenamiento y el ajuste de hiperparámetros se necesitarían muchos recursos. [3]

Teniendo en cuenta la profundidad definida en este proyecto, las redes definidas son poco profundas por lo que hacen falta menos tiempo, recursos de memoria y GPU para entrenarlas.

Además, al ser una red neuronal pequeña, realizar el ajuste de hiperparámetros como el learning rate o el dropout entre capas es más sencillo.

Tras utilizar keras tuner, la mejor red neuronal, que se puede ver en la Figura 5, obtuvo una precisión en el conjunto de testeo del 95.34% y en la Figura 6 se muestra la evolución de la precisión y perdida para dicho mejor modelo.

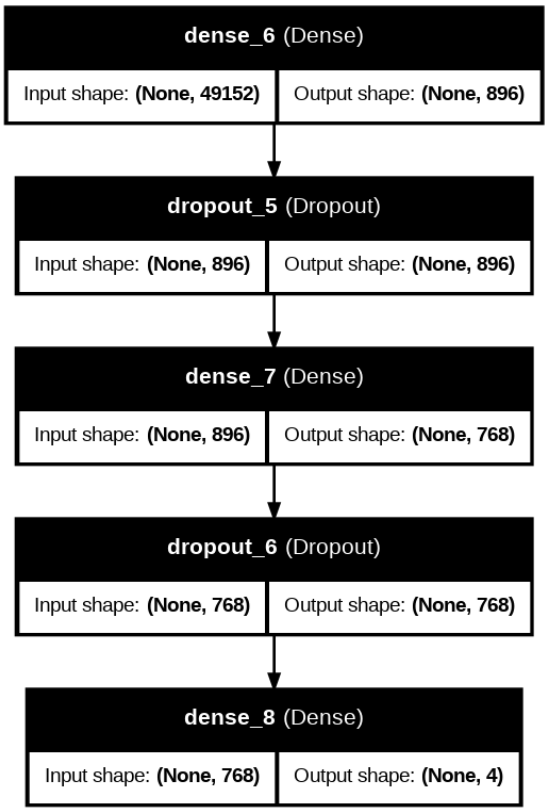

Figure 5: Mejor modelo encontrado

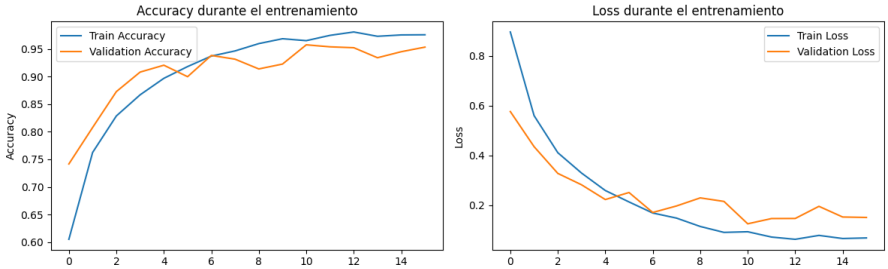

Figure 6: Precisión y pérdida durante el entrenamiento

3.2 Redes Convolucionales (Ver CONV Notebook)

Las redes neuronales convoluciones se utilizan típicamente para tareas de clasificación y visión por computador. Estas redes están formada por tres tipos de capas: Las capas convoluciones, la capa de agrupación y una capa totalmente conectada (densa).

La capa convolucional permite de entrada una imagen, por lo que a diferencia de los perceptrones multicapa, no haría falta aplanar los datos. La característica principal de las capas convolucionales es que tienen un detector de características (que normalmente el filtro suele ser una matrix 3x3) que se va aplicando a la imagen realizando cálculos con el filtro y los datos de la imagen. El resultado de dichos cálculos se almacenan en una matriz de salida [4].

Las capas convolucionales permite extraer características de las imágenes, función que es muy importante para el dataset OASIS debido a la distintos patrones que se pueden encontrar en los cerebros según el nivel de demencia de la persona.

Por otra parte, tenemos la capa de agrupación que se encarga de reducir la dimensión de los datos de entrada. A pesar de que se pierde información, utilizar esta capa permite reducir el riesgo de sobreajuste.

Por último, tenemos la capa densa que mediante la función de activación softmax se encarga de realizar la clasificación.

3.2.1 Pruebas con redes convolucionales

Para realizar las pruebas con las redes convolucionales, al igual que con el perceptrón multicapa, se ha usado keras tuner para definir distintos parámetros en las capas convolucionales y en las capas densas. Además también se han definido distintos parámetros para la tasa de aprendizaje.

La red convolucional que se ha definido tiene dos capas convolucionales seguidas cada una de una capa de agrupación. Para la primera capa convolucional se ha definido un valor entre 16 y 64 filtros y un tamaño del kernel entre 3x3, 4x4 y 5x5.

Para la segunda capa convolucional se ha definido un valor entre 32 y 128 filtros y el mismo tamaño de kernel que la primera capa convolucional. Los

filtros representan cuantos patrones diferentes puede aprender la capa.

Por último, para la penúltima capa densa se ha definido un valor entre 64 y 256 neuronas.

Tras aplicar RandomSearch, la mejor red convolucional obtenida se puede ver en la Figura 7. Con dicha red neuronal convolucional, se ha conseguido una precisión en el conjunto de pruebas de un 97,92%.

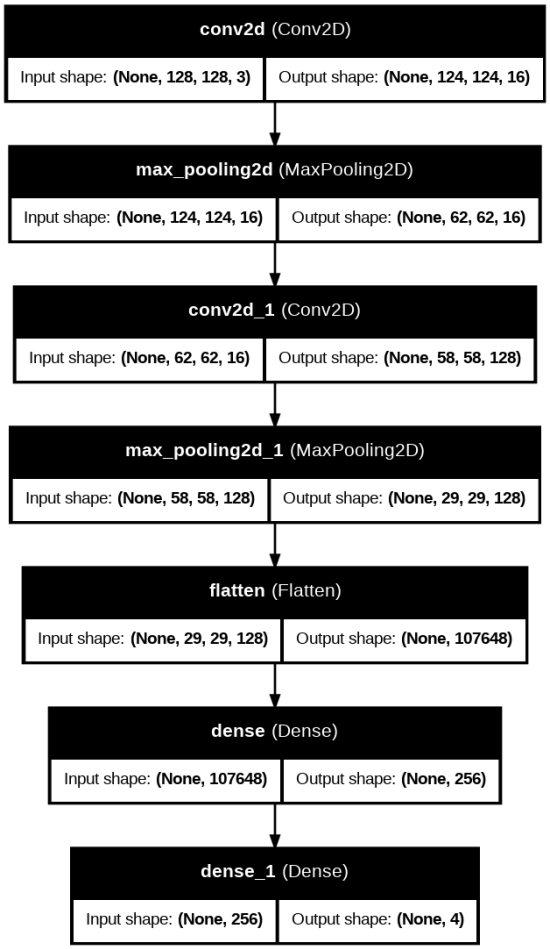

Figure 7: Red Convolucional

3.3 Redes preentrenadas (Ver Modelos Preentrenados Notebook)

Para esta sección, se han probado diferentes redes preentrendas aplicando a cada red fine-tunning y aumento de datos para ver cual de las redes preentrenadas es mejor para el conjunto de datos OASIS.

La primera red que se ha probado ha sido la ResNet 50 desarrollada por Microsoft Research. Los resultados de utilizar ResNet 50 con fine tunning y sin ampliación de datos es del 98,91% mientras que aplicando ampliación de datos es del 98,32%.

Como segunda red, se ha probado el modelo EfficientNetB2 obteniendo una precisión del 98.07% aplicándole fine-tunning y aumento de datos y una precisión del 98.22% con fine-tunning pero sin el aumento de datos. A diferencia de la red ResNet50, EfficientNetB2 es una red neuronal con menos parámetros, lo que permite realizar entrenamientos más rápido pero con este conjunto de datos, ResNet50 ha sido capaz de representar y clasificar mejor las imágenes. En la Figura 8 se muestra la gráfica de la precisión y pérdida durante el entrenamiento en los conjuntos de entrenamiento y validación del modelo ResNet50.

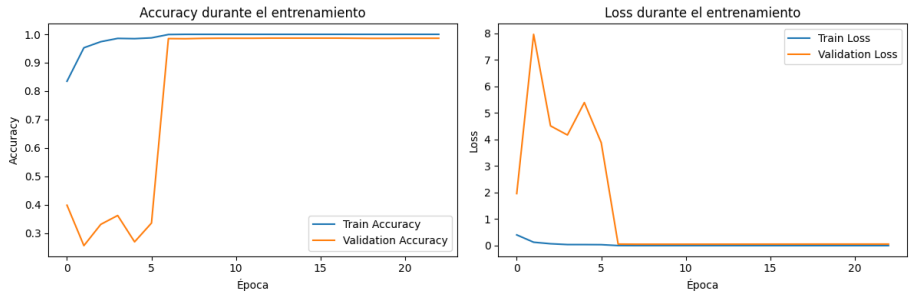

Figure 8: Precisión y pérdida del model ResNet50

En los dos modelos, con la ampliación de dato no se ha conseguido aumentar la precisión del modelo. Para este dataset, realizar esta técnica puede ser perjudicial porque estarías modificando la estructura del cerebro y podría provocar que se aprendan patrones falsos para detectar el nivel de demencia.

4 Modelos No Paramétricos (Vease Notebook Metodos No Parametricos)

En esta sección se van a probar diferentes métodos no paramétricos y se van a comparar sus resultados. Los métodos probados son K-Nearest Neighbours (KNN), Random Forest Classifier (RFC) y Decision Tree Classifier (DTC)

4.1 K-Nearest Neighbours (KNN)

KNN es un modelo no paramétrico que se puede utilizar para clasificación. Este modelo predice a que clase pertenece un nuevo dato a partir de los K datos más cercanos a dicho nuevo dato.

Para probar este modelo, se ha decidido ejecutar con valores diferentes de K entre 3 y 10. Para cada valor distinto obtenemos la precisión del modelo para

comparar los resultados. En la Figura 9 se muestra una gráfica de barras con dicha comparación. El mejor KNN encontrado ha sido con el valor K=3 con una precisión del 97,42%.

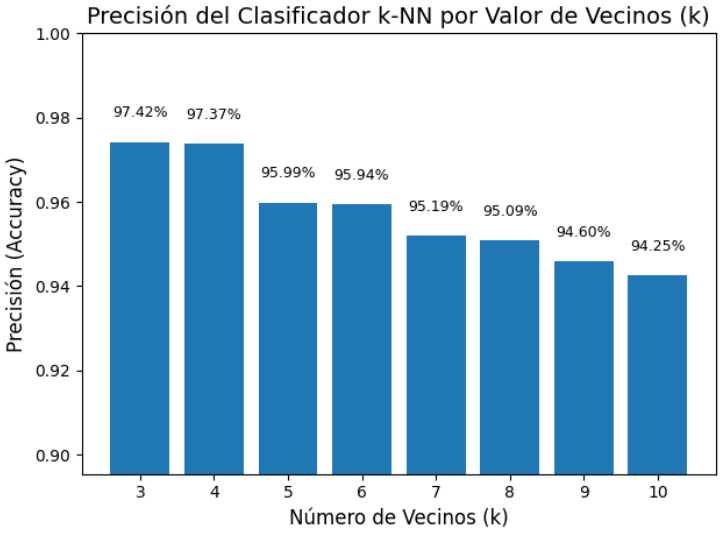

Figure 9: Precisión de los distintos KNN

4.1.1 Random Forest Classifier

Este método consiste en crear un conjunto de árboles de decisión donde a cada árbol se le proporciona unas características del dato de entrada. Cada arbol predice a que clase puede pertenecer el dato de entrada y se selecciona la clase predicha utilizando el metodo comité, es decir, por voto mayoritario.

Para probar este método no paramétrico se han utilizado diferentes números de árboles, siendo 10, 100 y 1000. Para cada cantidad se ha ejecutado el modelo y se ha obtenido su precisión.

A medida que el número de árboles aumentaba, se mejoraba la precisión del módelo. Finalmente, con el tamaño de 1000 árboles se ha obtenido una precisión del 97,77%.

4.1.2 Decision Tree Classifier

Para probar este método no paramétrico se han utilizado diferentes tamaños de profundidad del árbol siendo las siguientes: [2, 4, 6, 8, 10, 12, 15, 20, 25, 30]. Para cada profundidad se ha ejecutado el modelo y se ha obtenido su precisión.

Con una profundidad baja, el modelo no es capaz de separar correctamente los datos en las diferentes clases obteniendo precisiones muy bajas como del 30%. A medida que se aumentaba la profundidad, se mejoraba la precisión y se

reducía el error en los tests. Con una profundidad de 15, el modelo consiguió los mejores resultados con una precisión del 75%.

5 Resultados Finales

Tras aplicar diferentes pruebas con los modelos lineales, perceptrones multicapas, redes convolucionales, redes preentrenadas y modelos no paramétricos, en la Figura 10 se muestra una gráfica con la precisión de cada modelo utilizado. El modelo que mejores resultados ha obtenido es el modelo preentrenado ResNet50 con una precisión del 98.91%.

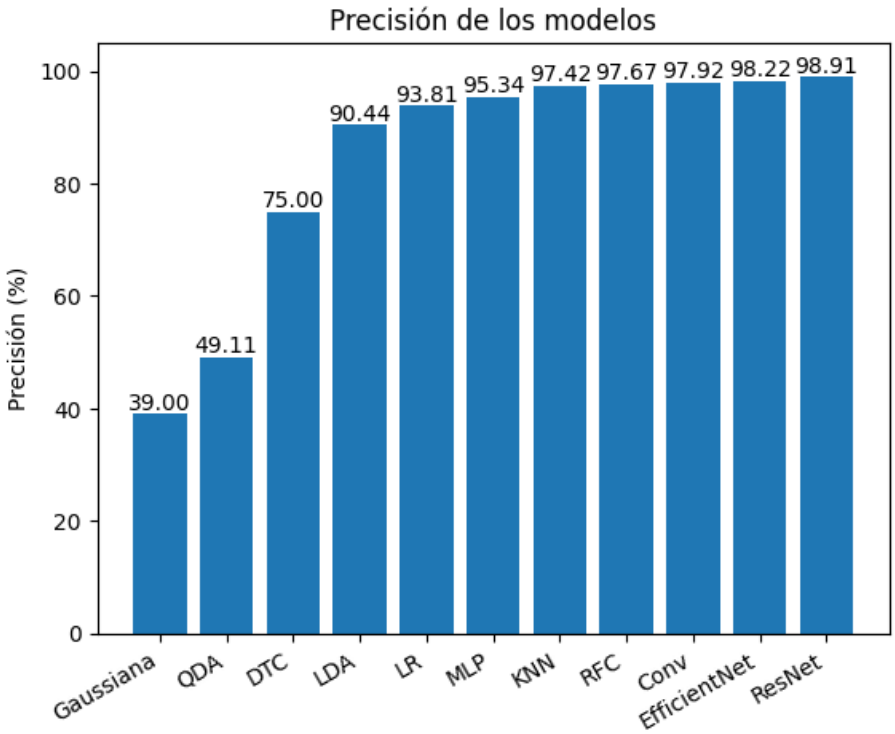

Figure 10: Resultados Finales

References

[1] N. Daithal, *Oasis alzheimer's detection*, https://www.kaggle.com/datasets/ninadaithal/imagesoasis, Kaggle dataset, accesado: 26 de septiembre de 2025, 2025.

[2] P. Morales-Brown, *Alzheimer's brain vs. typical brain: What to know*, https://www.medicalnewstoday.com/articles/alzheimers-brain-vs-normal-brain, Revisado por Heidi Moawad, M.D.; actualizado el 22 de marzo de 2024, 2024. Accessed: Sep. 21, 2025.

[3] E. Shah, *Multilayer perceptron in machine learning*, Scaler Topics, Última actualización: 2 Apr. 2024. [En línea]. Disponible: https://www.scaler.com/topics/multilayer-perceptron/, Apr. 2024.

[4] IBM, *¿qué son las redes neuronales convolucionales?* Accedido: 2025-10-03, 2025. [Online]. Available: https://www.ibm.com/es-es/think/topics/convolutional-neural-networks.